Javier Domínguez Gómez
jdg@member.fsf.org
Fingerprint: 94AD 19F4 9005 EEB2 3384 C20F 5BDC C668 D664 8E2B

v0.02 - Noviembre 2021

https://github.com/JavDomGom/videostego

Contents

1 Introducción

MPEG-4 Part 14 o MP4 es un formato multimedia digital basado en contenedores que comúnmente se usa para almacenar vídeo y audio, pero también se puede usar para almacenar otros datos como subtítulos e imágenes fijas. MP4 permite la transmisión a través de Internet. La única extensión de nombre de archivo oficial para los archivos MPEG-4 Parte 14 es .mp4, pero muchas tienen otras extensiones, más comúnmente .m4a y .m4p. La especificación del formato de archivo MPEG-4 se basó en la especificación del formato QuickTime. Los archivos MP4 se pueden utilizar para almacenar o transmitir contenido audiovisual completo en un solo archivo. Debido a que se puede dividir fácilmente en partes más pequeñas, se usa ampliamente en servicios de transmisión de video basados en tecnologías de tasa de bits adaptables como Smooth Streaming, MPEG-DASH y HLS.

Los archivos MP4 constan de varios bloques de datos consecutivos también llamados cajas o contenedores. Cada contenedor tiene un encabezado de 8 bytes: tamaño de fragmento de 4 bytes (big-endian, byte alto primero) y tipo de fragmento de 4 bytes, una de las siguientes firmas predefinidas:

- chap
- clip
- crgn
- ctab
- free
- ftyp
- imap
- jP2
- kmat
- load
- matt
- mdat
- meta
- mfra
- moof
- moov
- pdin
- PICT
- pnot
- scpt
- skip
- stts
- stsc
- stsz
- ssrc
- sync
- tmcd
- udta
- uuid
- wide

Estos a su vez suelen tener otros contenedores de segundo nivel, también con su encabezado correspondiente de 8 bytes. El contenedor `moov` es probablemente el más importante de todos los descritos anteriormente. Contiene pistas de vídeo y audio, información del encabezado de la película como escala de tiempo, duración, características de visualización de la película. Es bastante habitual encontrar el contenedor `moov` al final del archivo mp4, después de todos los demás contenedores para garantizar que todos los metadatos se lean antes de `moov` cuando el archivo se reproduce desde el servidor.

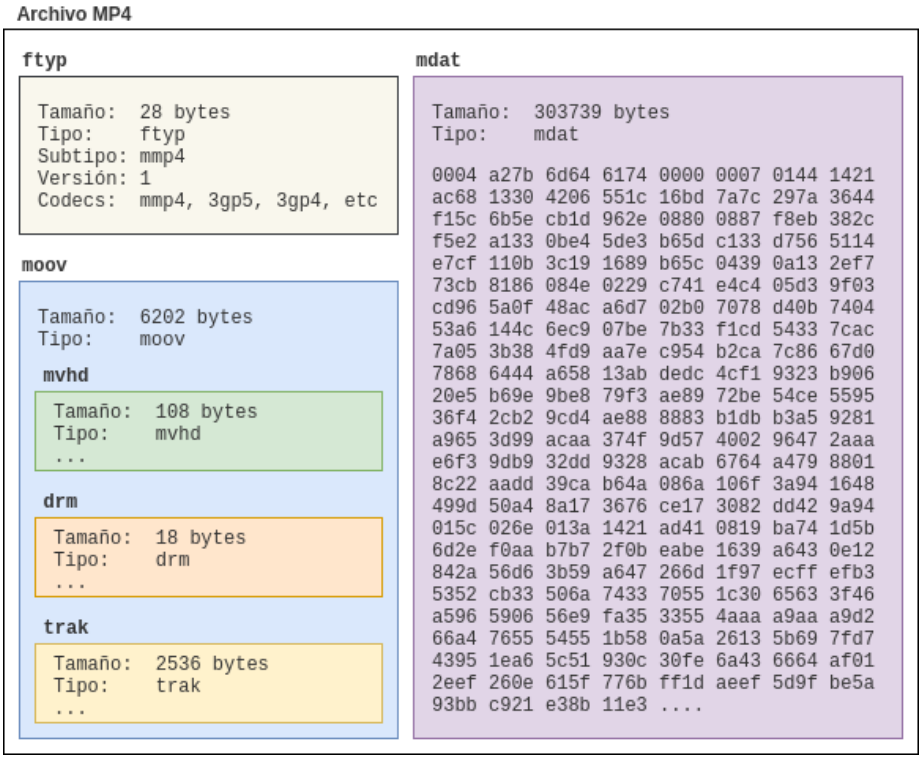

Figure 1: Ejemplo de arquitectura básica en un archivo MP4.

El bloque o contenedor `moov` no almacena información sobre audio/video en bruto. En su lugar, almacena todas las referencias a ubicaciones en el contenedor `mdat`, que es el contenedor donde realmente se almacena toda la información en bruto. El contenedor `mdat` tiene toda su información dividida en varios segmentos. Así pues, las referencias que almacena el contenedor `moov` apuntan a cada uno de esos segmentos para decodificarlos correctamente mediante un software de reproducción adecuado. Este software necesitará leer adicionalmente los contenedores `stts` (*sample-to-time table*) y `stsc` (*sample-to-chunk table*) para obtener la información de sincronización correcta.

2 Análisis de archivos MP4 por bloques

Para ilustrar este documento con ejemplos se ha utilizado el archivo **`sample_1.mp4`** que se puede encontrar en el repositorio de GitHub del proyecto.[1]

En términos generales, los archivos MP4 se dividen en tres secciones principales: **`ftyp`** (tipo de contenedor), **`mdat`** (media data)y **`moov`** (metadatos),

[1] https://github.com/JavDomGom/videostego/blob/main/mp4/sample_1.mp4

donde los metadatos contienen información general, información sobre la duración de cada frame de vídeo/audio, los offsets de cada frame de audio/vídeo, etc.

2.1 ftyp

En el primer bloque se encuentra la firma o *signature* del archivo. Nos servirá para identificar el tipo de archivo con el que estamos trabajando y otros datos adicionales como los formatos que es capaz de reconocer o con los que es compatible.

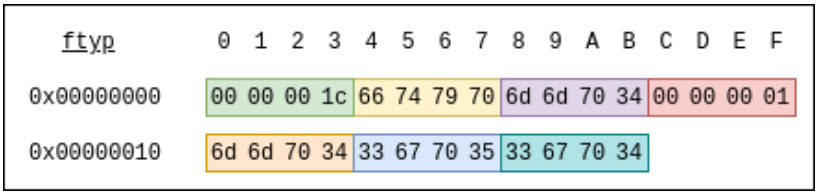

Figure 2: Detalle del bloque "ftyp".

- **Tamaño**: Los 4 primeros bytes del bloque indican el tamaño del mismo, en este caso 28 bytes (`0x0000001c`).
- **Tipo**: Los siguientes 4 bytes indican un código de cuatro carácteres. Se utiliza para identificar el tipo de contenedor principal empelado, la compatibilidad o el uso previsto de un archivo multimedia. En este caso el tipo es **`ftyp`** (`0x66747970`). Este tipo "ftyp" solo se aplica a los formatos de archivo contenedor MP4 o QuickTime (.mov) más nuevos.
- **Subtipo**: Los siguientes 4 bytes indican el subtipo o codec principal con otro código de 4 caracteres. En este caso **`mmp4`** (`0x6d6d7034`), quiere decir que el codec principal es *MPEG-4/3GPP Mobile Profile (.MP4/.3GP)*.
- **Versión**: Los 4 bytes que vienen a continuación representan el número de la versión del codec principal anterior, en este caso la versión es **`1`** (`0x00000001`).
- **Codecs compatibles**: Los últimos bytes hasta llegar al final del bloque se pueden dividir en secciones de 4 bytes. Cada una de estas secciones, representa el codec con el que el archivo es compatible, en este caso **`mmp4`** (`0x6d6d7034`), **`3gp5`** (`0x33677035`) *3GPP Media (.3GP) Release 5* y **`3gp4`** (`0x33677034`) *3GPP Media (.3GP) Release 4*. 3GP es el formato estándar requerido para los archivos multimedia enviados mediante el Servicio de Mensajería Multimedia (MMS) y los Servicios Multimedia Broadcast Multicast (MBMS).

El lector puede encontrar en la red una lista completa de todas las designaciones MP4/QuickTime ftyp conocidas hasta la fecha[2], así como un extracto de los diferentes formatos de archivo 3GPP detallado[3].

2.2 mdat (info)

En este archivo **`sample_1.mp4`** el segundo bloque es simplemente informativo, nos indicará información acerca del siguiente bloque.

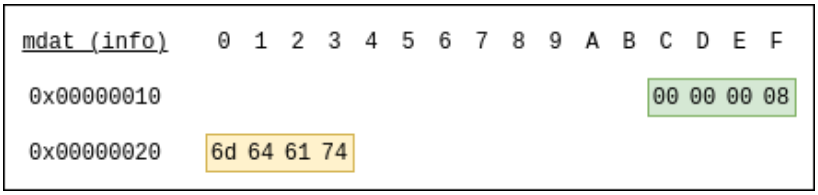

Figure 3: Detalle del primer bloque "mdat".

- **Tamaño**: Los 4 primeros bytes de este bloque nos indica el tamaño del mismo, en este caso **`8`** bytes (`0x00000008`).
- **Tipo**: Y los siguientes 4 bytes nos indican el tipo de contenedor que encontraremos en el siguiente bloque, que es **`mdat`** (`0x6d646174`).

2.3 mdat (data)

En este bloque encontraremos los el contenedor "mdat", que contendrá los todos los frames de vídeo y audio.

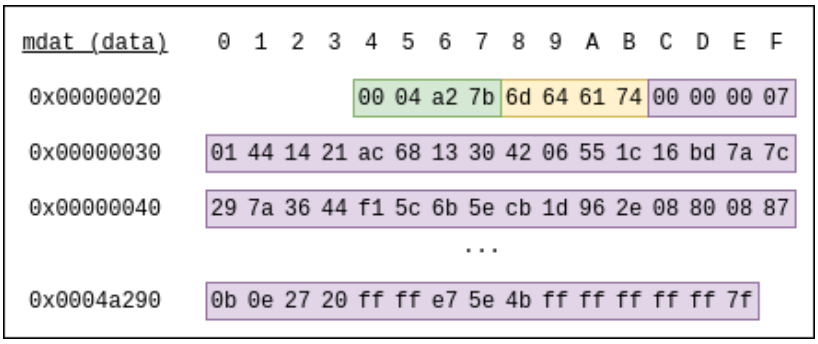

Figure 4: Detalle del segundo bloque "mdat".

- **Tamaño**: Los 4 primeros bytes de este bloque nos indica el tamaño del mismo, en este caso **`303739`** bytes (`0x0004a27b`).

[2] http://www.ftyps.com/
[3] http://www.ftyps.com/3gpp.html

- **Tipo**: Y los siguientes 4 bytes nos indican el tipo de contenedor en el que estamos, **`mdat`** (`0x6d646174`).
- **El resto de bytes**: Todos los bytes que vienen a continuación hasta el final del bloque son los media-data.

2.4 moov

El bloque **`moov`** se compone de varios sub-bloques. En general, `moov` seguirá a `ftyp`. Moov contiene metadatos e información básica relacionada con el audio y el vídeo. A continuación una lista de los principales sub-bloques o contenedores de `moov`:

- drm
- iods
- mvhd
- trak
- udta

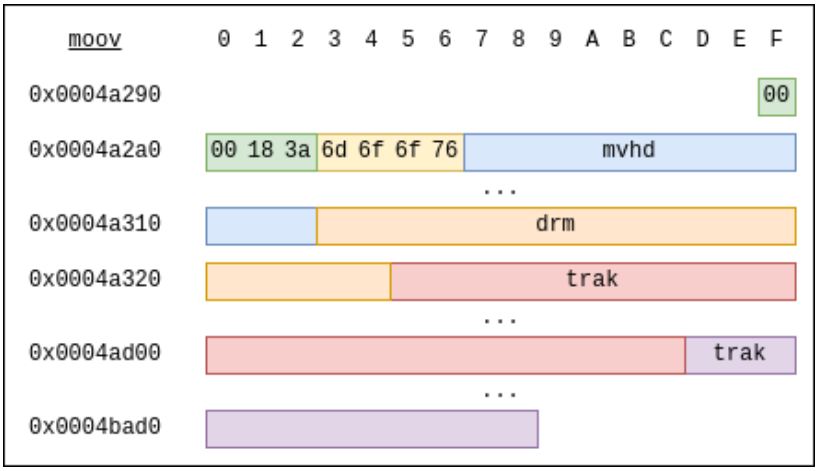

Figure 5: Detalle del bloque "moov".

2.4.1 mvhd

El bloque `mvhd` (Movie Header Box) contendrá los datos de la cabecera o header de la película.

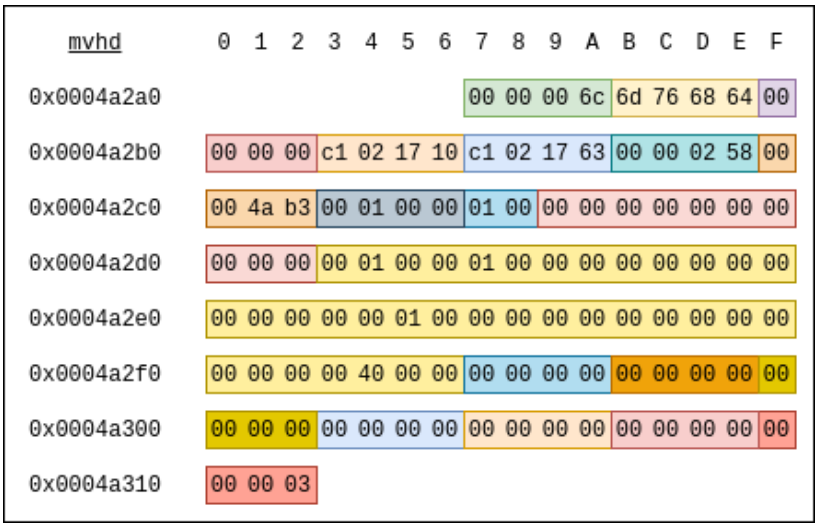

Figure 6: Detalle del bloque "mvhd".

- **box size**: 4 bytes. Indica el tamaño en bytes del bloque, en este caso **`108`** bytes (`0x0000006c`).
- **box type**: 4 bytes, es el tipo de bloque, en este caso **`mvhd`** (`0x6d766864`).
- **version**: 1 byte. Versión del bloque, pude ser 0 o 1, generalmente **`0`** (`0x00`).
- **flags**: 3 bytes, flags, en este ejemplo no hay (`0x000000`).
- **creation time**: 4 bytes. Hora de creación relativa a la hora UTC 1904-01-01 00:00:00 en segundos. En este ejemplo es **`3238139664`** (`0xc1021710`) que equivale a la fecha y hora 2006-08-11 11:14:24.
- **modification time**: 4 bytes. Hora de la última modificación (`0xc1021763`) que equivale a la fecha y hora 2006-08-11 11:15:47.
- **time scale**: 4 bytes. La escala de tiempo. En este ejemplo tiene un valor de **`600`** (`0x00000258`).
- **duration**: 4 bytes. La duración y el valor del campo time scale se pueden usar para calcular la duración real de la pista en segundos dividiendo el valor de duration entre el valor de time-scale. En este ejemplo duration tiene un valor de **`19123`** (`0x00004ab3`), y time duration tiene un valor de 600 que ya habíamos calculado antes, por lo tanto la pista tendrá una duración total de 19123/600 = **`31.87`** segundos.
- **rate**: 4 bytes. La velocidad de reproducción recomendada, los 16 bits superiores y los 16 bits inferiores son la parte entera y la parte decimal

del punto decimal respectivamente, es decir, formato [16.16], el valor de **`1.0`** (`0x00010000`) significa reproducción normal hacia adelante.

- **volume**: 2 bytes. Similar al campo rate, el formato es [8.8], **`1.0`** (`0x0100`) significa volumen máximo.
- **reserved**: 10 bytes, simplemente una cantidad de bytes reservados para uso del propietario del formato (QuickTime - Apple), en este caso no se le da uso (`0x00000000000000000000`).
- **matrix**: 36 bytes. Matriz de transformación de vídeo. Esta matriz define cómo mapear puntos de un espacio de coordenadas a otro. Modificando el contenido de una matriz de transformación, se pueden realizar varias operaciones de visualización de gráficos como traducción, rotación y el escalado. La matriz utilizada para lograr las transformaciones bidimensionales se describen matemáticamente mediante una matriz de 3 por 3.[4]
- **preview time**: 4 bytes. El valor de tiempo de la película en el que comienza la vista previa, en este caso no se le da uso (`0x00000000`).
- **preview duration**: 4 bytes. La duración de la vista previa de la película en unidades de escala de tiempo de la película.
- **poster time**: 4 bytes. El valor temporal del tiempo del cartel de la película, en este caso no se le da uso (`0x00000000`).
- **selection time**: 4 bytes. El valor de tiempo para la hora de inicio de la selección actual, en este caso no se le da uso (`0x00000000`).
- **selection duration**: 4 bytes. La duración de la selección actual en unidades de escala de tiempo de película, en este caso no se le da uso (`0x00000000`).
- **current time**: 4 bytes. El valor de tiempo para la posición de tiempo actual dentro de la película, en este caso no se le da uso (`0x00000000`).
- **next track id**: 4 bytes. Indica un valor que se utilizará para el número de identificación de la siguiente pista agregada a la película. En este caso el valor es **`3`** (`0x00000003`). 0 no es un valor de ID de pista válido.

2.4.2 drm

Debido a que a los proveedores de contenido y a los servicios de transmisión les gusta ganar dinero, el cifrado se usa generalmente para controlar quién puede reproducir un archivo de vídeo y cómo. Esto también se denomina "*Gestión de Derechos Digitales*" o "*Digital Rights Management*" (DRM).

[4] https://developer.apple.com/library/archive/documentation/QuickTime/QTFF/QTFFChap4/qtff4.html#/apple_ref/doc/uid/TP40000939-CH206-18737

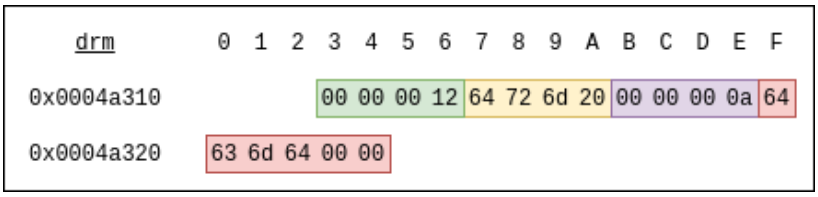

Figure 7: Detalle del bloque "drm".

- **box size**: 4 bytes. Indica el tamaño en bytes de este bloque, en este caso **18** bytes (0x00000012).
- **box type**: 4 bytes, es el tipo de bloque, en este caso "**drm** " (0x64726d20), nótese el espacio del final.
- **next box size**: 4 bytes. Indica el tamaño en bytes del bloque contenido dentro de este bloque drm, en este caso **10** bytes (0x0000000a).
- **file type**: 10 bytes. Indica el tipo de archivo, en este caso **dcmd** (Digital Cinema Master Digital) (0x64636d64), es el master digital DSM convertido ya a los estándares DCI, pero sin comprimir.

El método de cifrado más común y estandarizado para contenido encapsulado MP4 se llama Cifrado común. Cuando se utiliza Common Encryption, el cifrado solo se aplica a la carga útil mdat. Los metadatos permanecen sin cifrar.

También se agrega información a los metadatos para indicar que el contenido está encriptado y cómo. Esta información también incluye los ID de las claves necesarias para descifrar el contenido.

La forma de utilizar los ID de clave para obtener las claves reales depende de la solución DRM específica que se utilice, pero este es el único aspecto específico del proveedor. Qué algoritmos de cifrado usar y a qué aplicarlos está estandarizado.

2.4.3 trak

El bloque moov puede contener varios bloques de tipo **trak**. Cada uno define una pista individual de una película, y esta puede tener una o más. Cada pista es independiente de las otras pistas de la película y lleva su propia información temporal y espacial.

A continuación los propósitos que tienen los bloques trak:

- Para contener referencias y descripciones de media data.
- Para contener pistas modificadoras (interpolaciones, etc).

- Para contener información sobre la paquetización para protocolos de *streaming* (*hint tracks*). Estos *hint tracks* pueden contener referencias a *samples* de media data o copias del estos *samples*.[5]

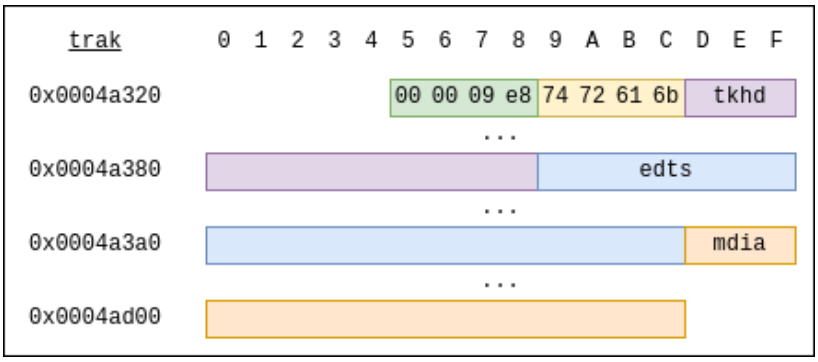

Figure 8: Detalle del bloque "trak".

Cada bloque `trak` contiene a su vez muchos otros bloques como `tkhd`, `edts`, `mdia`, etc. Y estos a su vez contienen más bloques como `mdhd`, `hdlr`, `minf`, etc. Véase un ejemplo en el siguiente esquema jerárquico:

```
...
└──[trak] Contenedor para una pista de vídeo o stream individual.
   ├──[tkhd] Track header, información general sobre la pista.
   ├──[edts] Contenedor con una lista de ediciones.
   └──[mdia] Contenedor con la información multimedia de la pista.
      ├──[mdhd] Media header, información multimedia general.
      ├──[hdlr] Handler, donde se declara el tipo de handler que usa la pista.
      └──[minf] Información multimedia detallada.
         ├──[vmhd] Video media header, información general (solo pista de audio).
         ├──[dinf] Contenedor con data information.
         └──[stbl] Sample table, contenedor con el mapeo de tiempo/espacio.
            ├──[stsd] Sample descriptions (tipos de codec, inicialización, etc).
            ├──[stts] (Decoding) time-to-sample.
            ├──[stss] Sync sample table (puntos de acceso aleatorios).
            ├──[stsc] Sample-to-chunk, información parcial sobre data-offsets.
            ├──[stsz] Sample sizes (framing).
            └──[stco] Chunk offset, información parcial sobre data-offsets.
```

3 Ocultación de información

Ahora que ya conocemos la arquitectura o la estructura de datos de la que se compone un archivo MP4 podremos realizar algunas modificaciones en algunos

[5] https://developer.apple.com/library/archive/documentation/QuickTime/QTFF/QTFFChap3/qtff3.html#/apple_ref/doc/uid/TP40000939-CH205-69871

bytes, en bloques y zonas muy concretas, no podremos modificar cualquier byte. En primer lugar hay que plantear un mensaje. Este mensaje M a ocultar puede ser una cadena de texto plano como "`Hello world!`" o una cadena de texto cifrado como "`ce415a50bb09e42e7420d73196e47324`". En todos los casos el mensaje se tratará como texto plano, es decir, una cadena de caracteres ASCII. Si el mensaje se hubiese cifrado previamente con algún algoritmo criptográfico o mediante alguna función *hash*, el receptor leerá el mensaje en su forma original, tal como se escribió en el fichero, no se descifrará.

Figure 9: Proceso de envío y recepción del mensaje "M".

3.1 Espacio de trabajo

Como se ha visto en puntos anteriores, en los que se ha realizado un análisis de cada una de las partes o contenedores que componen un archivo MP4, cada contenedor o bloque tiene un propósito específico. Esto quiere decir que no podremos escoger cualquier bloque de datos y hacer modificaciones en él. Si queremos realizar alguna modificación en el archivo un buen espacio de trabajo es el bloque "`mdat`" de datos, pues aquí residen los frames de las pistas de vídeo y datos relativos a las pistas de audio. Suele ser un bloque bastante amplio, con gran cantidad de bytes, lo que nos proporcionará cierta flexibilidad.

No se han de modificar ni los primeros ni los últimos bytes de este bloque, ya que dependiendo del tipo y subtipo de archivo MP4 estas zonas del bloque pueden contener algunos metadatos que es mejor no modificar, si no se podrían levantar sospechas e incluso corromper el bloque y como consecuencia el archivo, lo que podría provocar que no se reproduzca correctamente en algunos dispositivos y programas. Así pues el algoritmo de escritura dividirá el tamaño del bloque en 3 partes iguales y se establecerá el tercio central (2/3) como el espacio de trabajo, donde se realizarán las modificaciones oportunas para ocultar nuestro mensaje.

Para ilustrar este documento con ejemplos se ha utilizado un archivo MP4 llamado **`sample_1.mp4`** y que se puede encontrar en el repositorio de GitHub del proyecto.[6] En este archivo, el bloque de datos "`mdat`" comienza en el offset "`0x00000024`". Si lo dividimos en tres partes iguales, el segundo tercio comienza en el offset `0x00018ba2`, y se extiende hasta el offset "`0x0003171f`", lo que quiere decir que en este archivo MP4 tendremos un espacio de trabajo de 101245 bytes.

[6] https://github.com/JavDomGom/videostego/blob/main/mp4/sample_1.mp4

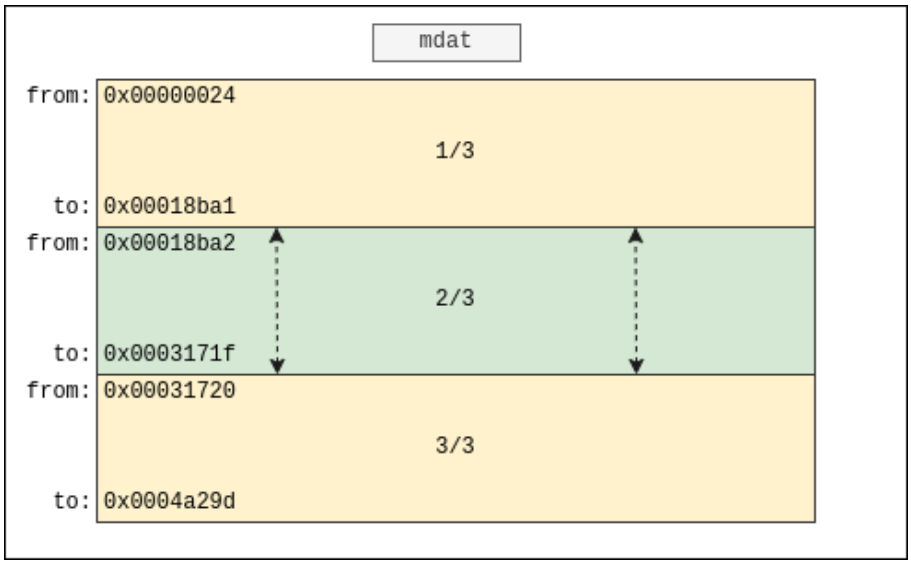

Figure 10: Zona central del bloque "mdat".

Según el archivo MP4 que utilicemos dispondremos de más o menos cantidad de bytes para nuestro espacio de trabajo. Así pues, cuanto más tamaño (duración de la película) tenga el archivo MP4 con el que se trabaje más grande será dicho espacio.

3.2 Algoritmo de escritura

Ahora que ya sabemos dónde se encuentra nuestro espacio de trabajo y qué capacidades podemos continuar con la escritura del mensaje.

Cada caracter ASCII del mensaje hará uso de 8 bytes del espacio de trabajo en el bloque de datos "`mdat`". Se ha escogido esta estrategia porque si se utilizase un byte para cada caracter del mensaje, este se podría ver fácilmente en una inspección del archivo MP4 si este se abre con algunos editores de texto. Por otro lado, sobrescribir un byte como `0xb7` por un byte como `0xf2` levantaría más sospechas que si se aumenta o disminuye únicamente un bit, el bit menos significativo (LSB)[7], es decir, sobrescribir un byte como `0xb7` por un byte como `0xb8`, o `0xff` por `0xfe`. Al fin y al cabo, un caracter ASCII tiene una representación binaria de 8 bits.

[7] https://en.wikipedia.org/wiki/Bit_numbering#Least_significant_bit

Char		*Hex*		*Bin*
a	$\Rightarrow$	`0x61`	$\Rightarrow$	`01100001`
b	$\Rightarrow$	`0x62`	$\Rightarrow$	`01100010`
c	$\Rightarrow$	`0x63`	$\Rightarrow$	`01100011`
...	$\Rightarrow$	...	$\Rightarrow$	...

La longitud del mensaje de entrada M en base 2 o binario es $|M_2|$. Cada bit (b_i) del caracter se utilizará para buscar paridad con cada byte (B_i) del bloque "`mdat`" de modo que `0` se utilizará marcar aquellos bytes que han de ser pares, y `1` para los impares, y si no coinciden en paridad o imparidad se modificará el byte (B_i) del bloque sumando o restando una unidad para hacer que coincidan. El algoritmo empleado para modificar los bytes que lo requieran se puede representar mediante la siguiente función recursiva definida por intervalos:

$$B_i + \sum_{i=0}^{|M_2|} \begin{cases} 0 & if \quad ([B_i \wedge b_i] \mod 2 = 0) \vee ([B_i \wedge b_i] \mod 2 \neq 0) \\ \begin{cases} 1 & if \quad B_i < \texttt{0xff} \\ -1 & otherwise \end{cases} & otherwise \end{cases}$$

Es decir, si b_i y B_i ambos son pares, el byte B_i se queda como está, no se modifica, en caso contrario el byte B_i se incrementará una unidad siempre que sea un byte menor que `0xff`, si no se le restará una unidad.

En los siguientes puntos se explica en detalle el funcionamiento del algoritmo con bytes reales, y los pasos a realizar en cada fase de escritura del mensaje M.

3.2.1 Cálculo de la longitud de M en bits

Para calcular la longitud de bits que tiene el mensaje de entrada M deberemos hacer una conversión a base 2 o binario. Lo más sencillo es multiplicar el número total de caracteres ASCII del mensaje por 8, ya que cada carácter ASCII equivale a 8 bits. Así pues la longitud de M en base 2 se definirá como $|M_2|$

M		$Bits \times Chars$		$Longitud$
`Hello world!`	$=$	8×12	$\Rightarrow$	$\|M_2\| = 96$
`Quedamos a las 15:33 donde siempre`	$=$	8×34	$\Rightarrow$	$\|M_2\| = 272$
`No le busques 3 pies al gato`	$=$	8×28	$\Rightarrow$	$\|M_2\| = 224$
`ce415a50bb09e42e7420d73196e47324`	$=$	8×32	$\Rightarrow$	$\|M_2\| = 256$

Para este ejemplo usaremos como valor de M el mensaje "`Hello world!`", que hará un uso de 96 bytes. La longitud del mensaje de entrada $|M|$ es un dato que se ha de reservar, ya que se utilizará para algunos cálculos más adelante.

3.2.2 Definición y escritura de la cabecera

La cabecera ocupará 2 + 32 bytes, en total 34 bytes. Los dos primeros bytes se utilizarán para establecer el tamaño total de bytes que vamos a usar para ocultar nuestro mensaje M más los 34 bytes de la cabecera, y se escribirá en base 16 o hexadecimal. Por lo tanto estos dos bytes tendrán un valor mínimo de `0x0022` (34 bytes de la cabecera) y un valor máximo de `0xffff` (65535 bytes).

En primer lugar iremos al offset `0x00018ba2`, que es donde anteriormente habíamos calculado que comienza el segundo tercio del bloque "`mdat`". Ahí encontraremos como dos primeros bytes `0x40` y `0xc4`. En el punto anterior calculamos para ocultar el mensaje de entrada M vamos a necesitar 96 bytes. A esta cifra de 96 le tenemos que sumar los 34 que ocupará siempre la cabecera, por lo tanto 96 + 34 = 130, que en hexadecimal es `0x82`. Así pues sobrescribiremos los dos bytes `0x40c4` por `0x0082`.

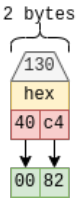

Figure 11: Escritura del tamaño total que se usará.

Los otros 32 bytes de la cabecera están reservados para escribir una etiqueta de 4 caracteres que servirá para identificar si el archivo MP4 ya ha sido modificado por este software. Esos cuatro caracteres son "`vstg`", que es un acrónimo de "`videostego`". Deberemos convertir cada uno de estos caracteres a su valor en binario.

Char		*Hex*		*Bin*
v	⇒	`0x76`	⇒	`01110110`
s	⇒	`0x73`	⇒	`01110011`
t	⇒	`0x74`	⇒	`01110100`
g	⇒	`0x67`	⇒	`01100111`

Ahora que ya conocemos el valor binario que tiene cada caracter, emplearemos el algoritmo de escritura y utilizaremos cada bit de cada caracter para buscar paridad con cada byte de los actuales 32 bytes que estamos leyendo. Si el byte que se encuentra en el cursor de lectura es par, por ejemplo `0xca`, y nuestro bit es `0`, el byte se deja como está, no se modificará. En caso contrario se le sumará una unidad, siempre que sea un byte inferior a `0xff`, si no se le restará una unidad. Aplica el mismo principio para los impares, es decir, si el

byte que se encuentra en el cursor de lectura es impar, por ejemplo `0xfb`, y nuestro bit es `1`, el byte se deja como está, y en caso contrario se modificará de la misma manera que los pares, sumando o restando una unidad para conseguir que estén alineados en una comparación de paridad.

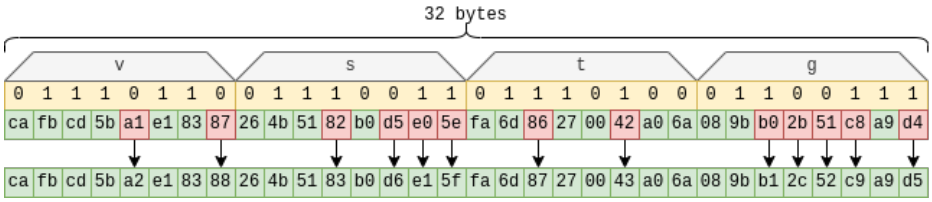

Figure 12: Escritura de la etiqueta "vstg" en la cabecera.

3.2.3 Conversión del mensaje a binario

Anteriormente decidimos que nuestro mensaje será "`Hello world!`". Lo primero que debemos hacer es convertir cada uno de los caracteres a binario.

Char		*Hex*		*Bin*
H	⇒	0x48	⇒	01001000
e	⇒	0x65	⇒	01100101
l	⇒	0x6c	⇒	01101100
l	⇒	0x6c	⇒	01101100
o	⇒	0x6f	⇒	01101111
	⇒	0x20	⇒	00100000
w	⇒	0x77	⇒	01110111
o	⇒	0x6f	⇒	01101111
r	⇒	0x72	⇒	01110010
l	⇒	0x6c	⇒	01101100
d	⇒	0x64	⇒	01100100
!	⇒	0x21	⇒	00100001

El proceso que viene ahora es exactamente igual al que hemos empleado en la cabecera para escribir la etiqueta "`vstg`", es decir, usar cada bit del mensaje para buscar paridad con cada byte que vaya leyendo el puntero de lectura, solo que ahora en vez de leer, comparar y sobrescribir sobre 32 bytes lo haremos sobre los siguientes 96 bytes, un dato que calculamos y reservamos anteriormente.

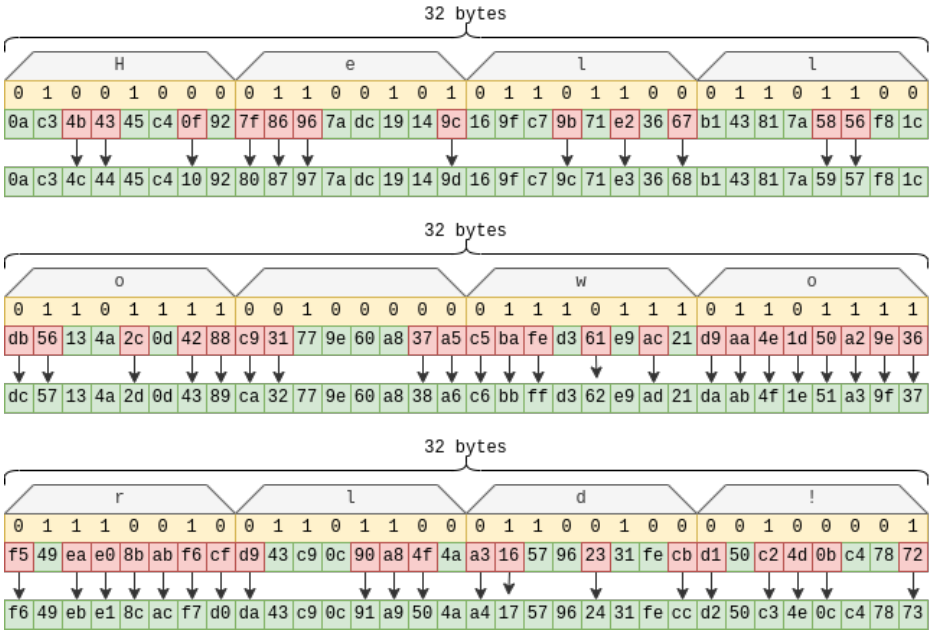

Figure 13: Escritura del mensaje sobre el archivo MP4 original.

3.3 Algoritmo de lectura

Dado un archivo de entrada, se deberán leer todas las cabeceras de cada bloque que lo compone. El objetivo es encontrar un bloque cuyo tipo sea "`mdat`" y que su tamaño sea superior a 8 bytes, pues existe la posibilidad de encontrar un bloque de tipo "`mdat`" que solo contenga información sobre el nombre del siguiente bloque, que podrá ser también de tipo "`mdat`", y este ocupará 8 bytes. Por ejemplo en el offset `0x0000001c` del archivo **`sample_1.mp4`** utilizado de ejemplo.

```
- offset - | 0 1  2 3  4 5  6 7  8 9  A B  C D  E F| 0123456789ABCDEF
0x00000000 |0000 001c 6674 7970 6d6d 7034 0000 0001| ....ftypmmp4....
0x00000010 |6d6d 7034 3367 7035 3367 7034 0000 0008| mmp43gp53gp4....
0x00000020 |6d64 6174 0004 a27b 6d64 6174 0000 0007| mdat...{mdat....
0x00000030 |0144 1421 ac68 1330 4206 551c 16bd 7a7c| .D.!.h.0B.U...z|
```

Figure 14: Bloque "mdat" solo con el nombre del siguiente bloque.

El bloque "`mdat`" con un tamaño superior a 8 bytes comienza en este caso en el offset `0x00000024`. A partir de aquí, los primeros 4 bytes indican el tamaño total del bloque, que en este caso es de 303739 bytes (`0x0004a27b`).

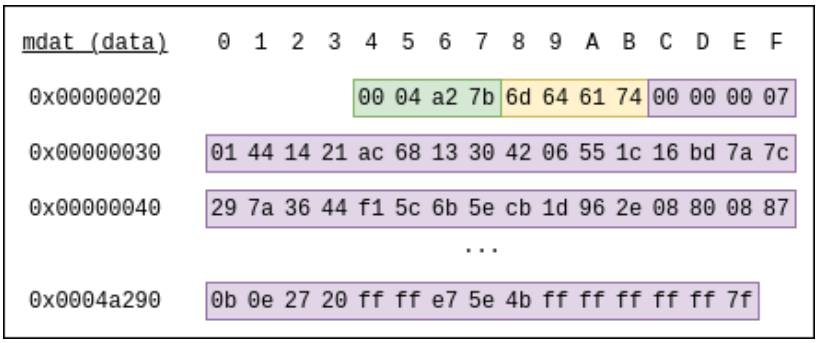

Figure 15: Detalle del bloque "mdat" con los datos a leer.

El siguiente paso es dividir el tamaño total del bloque entre 3, pues si se ha escrito algún mensaje oculto en el archivo se habrá hecho a partir del segundo tercio del bloque. En este ejemplo el segundo tercio del bloque "`mdat`" comienza en el offset `0x00018ba2`, y termina en el offset `0x0003171f`, tal y como se muestra en la siguiente imagen.

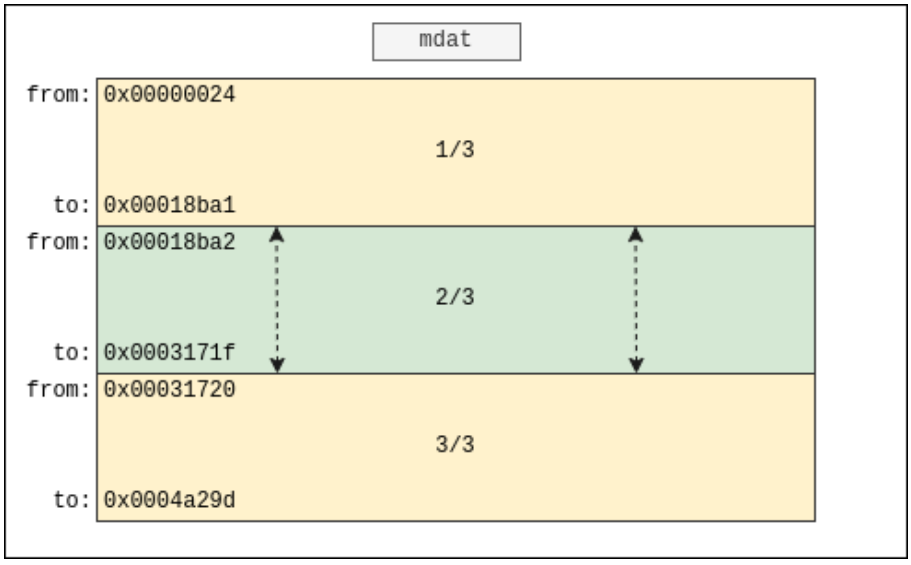

Figure 16: Zona central del bloque "mdat".

A partir de aquí, los dos primeros bytes nos indicarán el tamaño total de bytes que tenemos que leer y procesar para descifrar el mensaje oculto, si lo hubiera. En este caso los dos primeros bytes son `0x0082`, lo que quiere decir que vamos a tener que leer y procesar un total de 130 bytes, incluidos los dos bytes presentes.

Figure 17: Longitud de bytes a leer.

$$size = (B_0 + B_1)_{10}$$

A continuación hay que leer los siguientes 32 bytes y comprobar por cada uno de ellos su paridad. En caso de que el byte sea par, por ejemplo `0xca`, se obtendrá un 0, y si el byte es impar, por ejemplo `0xfb`, se obtendrá un 1, formando así una cadena binaria $|type|_2^{32}$ que se podrá leer a posteriori como una cadena de 32 bits (4 bytes).

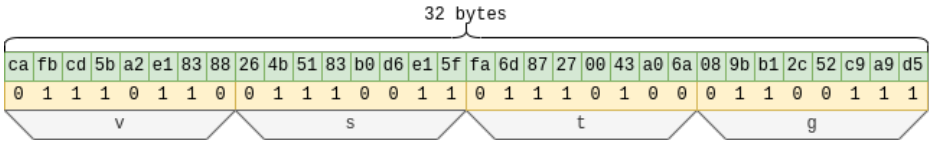

Figure 18: OP_CODE o type "vstg".

$$type = b_i \sum_{i=2}^{34} \begin{cases} 0 & if\ B_i \mod 2 = 0 \\ 1 & otherwise \end{cases}$$

Si los 32 bits (4 bytes) resultantes representaran los 4 caracteres ASCII `vstg` se consideraría que el archivo contiene un mensaje oculto en los siguientes bytes hasta completar los 130 bytes que leímos en la cabecera. En caso contrario, no se continúa y se descarta la posibilidad de que en el archivo exista algún mensaje oculto escrito con este software. Hay que tener en cuenta que ya hemos leído 2+32 bytes, 2 del tamaño y 32 de este flag u OP_CODE `vstg`, esto quiere decir que aún quedan por leer 96 bytes.

Los siguientes 96 bytes se leerán empleando el mismo algoritmo de lectura que acabamos de usar en la lectura del flag `vstg`.

$$if\ (type)_{ASCII} = \text{"}\texttt{vstg}\text{"}\ ;\ M = b_i \sum_{i=34}^{size} \begin{cases} 0 & if\ B_i \mod 2 = 0 \\ 1 & otherwise \end{cases}$$

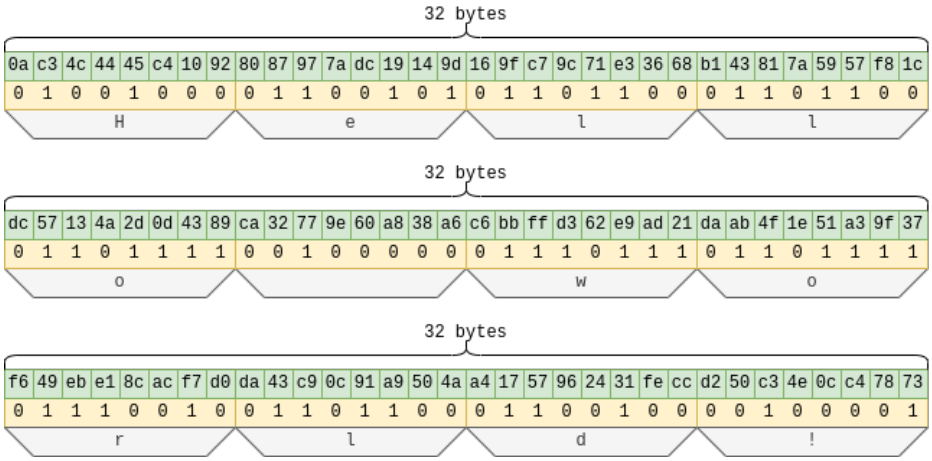

Figure 19: Longitud de bytes a leer.

En este ejemplo la cadena de bits `01001000 01100101 01101100 01101100 01101111 00100000 01110111 01101111 01110010 01101100 01100100 00100001` equivale al mensaje "`Hello world!`" en texto plano.

3.4 Capacidades

El mensaje M que se quiera ocultar tendrá una longitud variable, pero en ningún caso puede superar la longitud de `0xffff` (65535) menos 2+32 bytes de la cabecera, es decir, podrá una longitud máxima de 65501 bytes. Si cada caracter del mensaje va a ocupar 8 bytes, la longitud máxima del mensaje será de 8187 caracteres.

Si en futuras actualizaciones de Videostego se aumentara la cantidad de bytes reservados al tamaño de lectura, por ejemplo de los 2 bytes actuales a 3 bytes, el tamaño máximo sería de `0xffffff` (16777215) menos 3+32 bytes de la cabecera, en total 16777180 bytes, que serían 2097147 caracteres, pero por encima de todo hay que tener en cuenta que el tamaño máximo de bytes a escribir o leer no debe superar nunca un tercio de la cantidad total de bytes del contenedor "`mdat`", y en el caso del archivo usado de ejemplo es una capacidad total de 101245 bytes, equivalente a 12655 caracteres.

3.5 Debilidades

- Si se evalúa la paridad de todos los bytes del bloque "`mdat`" se extrae una cadena binaria de considerable longitud. Esta se podría convertir a caracteres ASCII, y entre una cadena de texto sin sentido podría encontrarse alguna subcadena que sí lo tenga, siempre y cuando el mensaje M que se escribiera fuera una cadena de texto plano.

- La lectura de posibles mensajes ocultos previamente escritos con videostego no funciona si los archivos MP4 son procesados a través de plataformas como Twitter, LinkedIn o Youtube. Como se puede ver en las siguientes imágenes, estas plataformas modifican la información de los frames añadiendo gran cantidad de bytes, los cambian por completo y además eliminan y añaden metadatos en varios contenedores.

Local

```
[ftyp] (0x00000000)      28 bytes
[mdat] (0x0000001c)       8 bytes
[mdat] (0x00000024)  303739 bytes
[moov] (0x0004a29f)    6202 bytes
|
├──[mvhd] (0x0004a2a7)     108 bytes
├──[drm ] (0x0004a313)      18 bytes
├──[trak] (0x0004a325)    2536 bytes
|   |
|   ├──[tkhd] (0x0004a32d)      92 bytes
|   ├──[edts] (0x0004a389)      36 bytes
|   └──[mdia] (0x0004a3ad)    2400 bytes
|       |
|       ├──[mdhd] (0x0004a3b5)      32 bytes
|       ├──[hdlr] (0x0004a3d5)      53 bytes
|       └──[minf] (0x0004a40a)    2307 bytes
|           |
|           ├──[smhd] (0x0004a412)      16 bytes
|           ├──[dinf] (0x0004a422)      36 bytes
|           └──[stbl] (0x0004a446)    2247 bytes
|               |
|               ├──[stsd] (0x0004a44e)     103 bytes
|               ├──[stts] (0x0004a4b5)      24 bytes
|               ├──[stsc] (0x0004a4cd)     100 bytes
|               ├──[stsz] (0x0004a531)    1016 bytes
|               └──[stco] (0x0004a929)     996 bytes
└──[trak] (0x0004ad0d)    3532 bytes
    |
    ├──[tkhd] (0x0004ad15)      92 bytes
    ├──[edts] (0x0004ad71)      36 bytes
    └──[mdia] (0x0004ad95)    3396 bytes
        |
        ├──[mdhd] (0x0004ad9d)      32 bytes
        ├──[hdlr] (0x0004adbd)      53 bytes
        └──[minf] (0x0004adf2)    3303 bytes
            |
            ├──[vmhd] (0x0004adfa)      20 bytes
            ├──[dinf] (0x0004ae0e)      36 bytes
            └──[stbl] (0x0004ae32)    3239 bytes
                |
                ├──[stsd] (0x0004ae3a)     171 bytes
                ├──[stts] (0x0004aee5)     152 bytes
                ├──[stss] (0x0004af7d)     112 bytes
                ├──[stsc] (0x0004afed)     736 bytes
                ├──[stsz] (0x0004b2cd)    1788 bytes
                └──[stco] (0x0004b9c9)     272 bytes
```

Youtube

```
[ftyp] (0x00000000)      24 bytes
[moov] (0x00000018)   11250 bytes
|
├──[mvhd] (0x00000020)     108 bytes
├──[trak] (0x0000008c)    4862 bytes
|   |
|   ├──[tkhd] (0x00000094)      92 bytes
|   ├──[edts] (0x000000f0)      36 bytes
|   └──[mdia] (0x00000114)    4726 bytes
|       |
|       ├──[mdhd] (0x0000011c)      32 bytes
|       ├──[hdlr] (0x0000013c)      95 bytes
|       └──[minf] (0x0000019b)    4591 bytes
|           |
|           ├──[dinf] (0x000001a3)      36 bytes
|           ├──[stbl] (0x000001c7)    4527 bytes
|           |   |
|           |   ├──[stsd] (0x000001cf)     151 bytes
|           |   ├──[stts] (0x00000266)      24 bytes
|           |   ├──[stsc] (0x0000027e)     280 bytes
|           |   ├──[stco] (0x00000396)     276 bytes
|           |   ├──[stsz] (0x000004aa)    1788 bytes
|           |   ├──[stss] (0x00000ba6)      48 bytes
|           |   └──[ctts] (0x00000bd6)    1952 bytes
|           └──[vmhd] (0x00001376)      20 bytes
├──[trak] (0x0000138a)    6272 bytes
|   |
|   ├──[tkhd] (0x00001392)      92 bytes
|   └──[mdia] (0x000013ee)    6172 bytes
|       |
|       ├──[mdhd] (0x000013f6)      32 bytes
|       ├──[hdlr] (0x00001416)      95 bytes
|       └──[minf] (0x00001475)    6037 bytes
|           |
|           ├──[dinf] (0x0000147d)      36 bytes
|           ├──[stbl] (0x000014a1)    5977 bytes
|           |   |
|           |   ├──[stsd] (0x000014a9)     105 bytes
|           |   ├──[stts] (0x00001512)      24 bytes
|           |   ├──[stsc] (0x0000152a)      40 bytes
|           |   ├──[stco] (0x00001552)     280 bytes
|           |   └──[stsz] (0x0000166a)    5520 bytes
|           └──[smhd] (0x00002bfa)      16 bytes
[mdat] (0x00002c0a)  879738 bytes
```

Figure 20: Diferencia tras subirlo a Youtube.

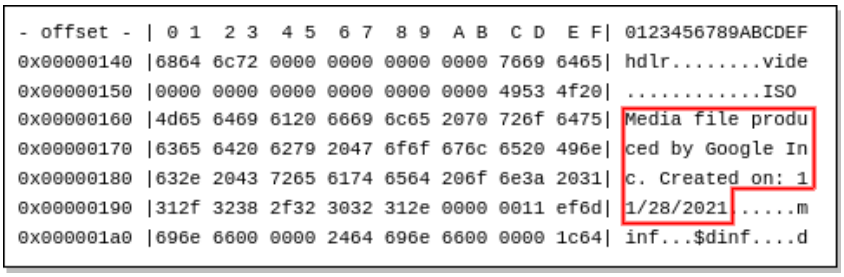

```
- offset - | 0 1  2 3  4 5  6 7  8 9  A B  C D  E F| 0123456789ABCDEF
0x00000140 |6864 6c72 0000 0000 0000 0000 7669 6465| hdlr........vide
0x00000150 |0000 0000 0000 0000 0000 0000 4953 4f20| ............ISO
0x00000160 |4d65 6469 6120 6669 6c65 2070 726f 6475| Media file produ
0x00000170 |6365 6420 6279 2047 6f6f 676c 6520 496e| ced by Google In
0x00000180 |632e 2043 7265 6174 6564 206f 6e3a 2031| c. Created on: 1
0x00000190 |312f 3238 2f32 3032 312e 0000 0011 ef6d| 1/28/2021......m
0x000001a0 |696e 6600 0000 2464 696e 6600 0000 1c64| inf...$dinf....d
```

Figure 21: Metadatos en el bloque "hdlr" tras subirlo a Youtube.